

Funcionamiento de la Red Neuronal de 2 Nodos

Arquitectura General

Entrada (10 características) → NODO 1 → NODO 2 → Salida (Probabilidad)

NODO 1: Capa Oculta

Función

Transforma las 10 características de entrada en una representación comprimida de 1 dimensión.

Operación Matemática

```
z1 = W1 · X + b1  
h1 = tanh(z1)
```

Donde:

- **W1**: Matriz de pesos (10 × 1)
- **X**: Vector de entrada (10 características)
- **b1**: Bias escalar
- **tanh**: Función de activación que comprime valores a rango [-1, 1]

¿Cuándo se activa?

- Se activa **en cada predicción** (forward pass)
- Se activa **en cada iteración de entrenamiento** (epoch)
- Es el **primer paso** obligatorio antes del Nodo 2

Salida

- Un valor escalar **h1** en el rango [-1, 1] que representa la "esencia" de los datos de entrada
-

NODO 2: Capa de Salida con Operaciones Matemáticas

Función

Toma la salida del Nodo 1 y aplica múltiples operaciones matemáticas para producir la probabilidad final.

Operaciones Matemáticas (en orden)

1. Combinación Lineal Base

$$z2_base = w2 \cdot h1 + b2$$

2. Potencia Ajustable

$$h1_powered = |h1|^{\beta}$$

- β : Parámetro aprendible (rango: 0.3 a 3.0)
- Eleva $h1$ a una potencia variable

3. Componente Cuadrático

$$h1_squared = h1^2$$

4. Producto de Hadamard

$$hadamard = h1 \cdot h1_powered$$

- Multiplicación elemento a elemento

5. Combinación No Lineal

$$z2_enhanced = z2_base + \alpha \cdot h1_powered + \gamma \cdot h1_squared + 0.1 \cdot hadamard$$

- α : Factor de escalamiento (parámetro aprendible)
- γ : Peso del término cuadrático (parámetro aprendible)

6. Activación Sigmoid

$$y_pred = \text{sigmoid}(z2_enhanced) = 1 / (1 + e^{(-z2_enhanced)})$$

- Convierte el valor a probabilidad en rango [0, 1]

¿Cuándo se activa?

- Se activa **inmediatamente después** del Nodo 1
- Se activa **en cada predicción y en cada epoch**
- Es el **segundo y último paso** del forward pass

Parámetros Aprendibles del Nodo 2

Parámetro	Función	Valor Inicial
W2	Peso lineal	Aleatorio (~0)
b2	Bias	0
α (alpha)	Escalamiento de potencia	1.0
β (beta)	Exponente de potencia	1.0
γ (gamma)	Peso del término cuadrático	0.5

 Flujo Completo: Nodo 1 → Nodo 2

Paso a Paso

1. **Entrada:** Vector X con 10 características

```
X = [edad, sexo, presión, colesterol, ...]
```

2. **NODO 1 se activa:**

```
h1 = tanh(W1 · X + b1)
Resultado: h1 = 0.45 (ejemplo)
```

3. **NODO 2 recibe h1 y aplica operaciones:**

```
z2_base = W2 · 0.45 + b2 = 0.23
h1_powered = |0.45|^1.2 = 0.38
h1_squared = 0.45² = 0.20
hadamard = 0.45 · 0.38 = 0.17

z2_enhanced = 0.23 + 1.0·0.38 + 0.5·0.20 + 0.1·0.17
              = 0.23 + 0.38 + 0.10 + 0.017
              = 0.727
```

4. **Activación final:**

```
y_pred = sigmoid(0.727) = 0.674
```

5. **Interpretación:**

Probabilidad de ser fumador = 67.4%
Predicción final: FUMADOR (> 0.5)

Cronología de Activación

Durante el Entrenamiento (500 épocas)

Por cada época (epoch):
Por cada batch de datos:

1. NODO 1 se activa $\rightarrow$ calcula h_1
2. NODO 2 se activa $\rightarrow$ calcula y_{pred}
3. Se calcula el error (loss)
4. Se calculan gradientes
5. Se actualizan W_1 , b_1 , W_2 , b_2 , α , β , γ

Total de activaciones: ~ 500 épocas $\times$ batches = miles de veces

Durante la Predicción

Por cada muestra a predecir:

1. NODO 1 se activa $\rightarrow$ calcula h_1
2. NODO 2 se activa $\rightarrow$ calcula y_{pred}
3. Se retorna la probabilidad

¿Por Qué Esta Arquitectura?

Ventajas del Nodo 1

- **Compresión de información:** Reduce 10 dimensiones a 1
- **Extracción de patrones:** Aprende combinaciones útiles de características
- **No linealidad:** tanh permite capturar relaciones complejas

Ventajas del Nodo 2 con Operaciones Matemáticas

- **Flexibilidad:** α , β , γ se adaptan durante el entrenamiento
- **No linealidad múltiple:** Combina potencias, cuadrados y productos
- **Mejor separación:** Las operaciones ayudan a distinguir fumadores de no fumadores
- **Focal Loss + Class Weights:** Compensa el desbalance de clases (78% no fumadores vs 22% fumadores)

Ejemplo Numérico Completo

Entrada

```
Persona:
- Edad normalizada: 0.6
- Sexo masculino: 1
- Presión alta: 0
- Colesterol alto: 1
- Triglicéridos altos: 1
- Glucosa alta: 0
- Bebe alcohol: 1
- Obesidad: 0
- Sobrepeso: 1
- Cintura alta: 1
```

NODO 1

```
z1 = (0.6*0.12 + 1*0.45 + 0*(-0.23) + ... + 1*0.31) + 0.05
    = 0.87
h1 = tanh(0.87) = 0.70
```

NODO 2

```
z2_base = 0.70 * 0.8 + 0.1 = 0.66
h1_powered = |0.70|^1.15 = 0.65
h1_squared = 0.70^2 = 0.49
hadamard = 0.70 * 0.65 = 0.46

z2_enhanced = 0.66 + 1.2*0.65 + 0.6*0.49 + 0.1*0.46
             = 0.66 + 0.78 + 0.29 + 0.05
             = 1.78

y_pred = sigmoid(1.78) = 0.856
```

Resultado

```
Probabilidad de ser fumador: 85.6%
Predicción: FUMADOR ✓
```

 Parámetros Finales Típicos

Después del entrenamiento, los parámetros suelen converger a valores como:

Parámetro	Valor Final Típico	Interpretación
α (alpha)	1.2 - 1.5	Amplifica la contribución de h1_powered

Parámetro	Valor Final Típico	Interpretación
β (beta)	0.9 - 1.3	Controla la no linealidad de la potencia
γ (gamma)	0.4 - 0.7	Peso del término cuadrático

Resumen Matemático

Forward Pass Completo

```
# NODO 1
z1 = W1 · X + b1
h1 = tanh(z1)

# NODO 2
z2_base = W2 · h1 + b2
h1_powered = |h1|^β
h1_squared = h1²
hadamard = h1 · h1_squared
z2 = z2_base + α·h1_powered + γ·h1_squared + 0.1·hadamard
y = sigmoid(z2)
```

Backward Pass (Entrenamiento)

```
# Calcular error
loss = FocalLoss(y, y_real) + L2_regularization

# Calcular gradientes
∇W1, ∇b1, ∇W2, ∇b2, ∇α, ∇β, ∇γ = gradient(loss)

# Actualizar parámetros (Adam optimizer)
W1 = W1 - learning_rate · ∇W1
b1 = b1 - learning_rate · ∇b1
W2 = W2 - learning_rate · ∇W2
b2 = b2 - learning_rate · ∇b2
α = α - learning_rate · ∇α
β = β - learning_rate · ∇β
γ = γ - learning_rate · ∇γ
```

Conclusión

La red funciona como un **pipeline secuencial**:

1. **Nodo 1** comprime y extrae patrones de las 10 características
2. **Nodo 2** toma esa información comprimida y aplica transformaciones no lineales complejas
3. Ambos nodos se **activan en cada predicción** y **aprenden juntos** durante el entrenamiento

4. Los parámetros α , β , y γ se **ajustan automáticamente** para maximizar la precisión

El resultado es una red simple (solo 2 nodos) pero poderosa gracias a las **operaciones matemáticas avanzadas** del Nodo 2.